

Reineke-RAG

Handbuch

Kurzanleitung für das Admin-Web-UI

100 % offline · on-premise

Stand 21. Mai 2026

1 · Worum geht es?

Dieses Handbuch beschreibt die tägliche Arbeit mit dem **Admin-Web-UI** von Reineke-RAG. Es richtet sich an Anwenderinnen und Anwender, die

- neue Dokumenten-Quellen indexieren,
- den Bestand pflegen (löschen, reindizieren),
- Agenten mit individuellem Persona-Prompt einrichten,
- nächtliche Auto-Ingest-Läufe konfigurieren,
- Konfigurationswerte anpassen oder
- Logs und Fehler nachverfolgen wollen.

Das Admin-UI ist ein normales Bootstrap-Web-Interface, läuft direkt im Backend und benötigt keine zusätzliche Anwendung. Aufruf:

```
http://<server>:8000/admin/
```

Voraussetzung: Das Backend läuft, der Server ist im internen Netz erreichbar. Für die nachfolgenden Screenshots wurde die Standard-Adresse <http://localhost:8000/admin/> verwendet.

Hinweis zur Authentifizierung. Das Admin-UI hat selbst keine Anmeldung — es lebt im Vertrauensmodell „intern erreichbar, Reverse-Proxy übernimmt ggf. TLS und SSO“. Stelle sicher, dass das Backend **nicht** öffentlich erreichbar ist.

2 · Erster Blick — die Übersicht

Nach dem Öffnen landet man auf der **Übersicht**. Sie zeigt die wichtigsten Statusinformationen auf einen Blick:

Reineke-RAG · Admin **Übersicht** Agenten Dokumente Ingest-Assistent Zeitplan Ingest-Verlauf Logs Konfiguration offline · DE

Übersicht Aktualisieren

Backend
läuft OK

Qdrant
erreichbar unter http://localhost:6333 OK

Ollama
erreichbar unter http://localhost:11434 OK

Embedding-Modell
bge-m3 OK

Chat-Modell
qwen2.5:32b-instruct-q4_K_M OK

Reranker
aktiv, lazy — erster Aufruf lädt 'BAAI/bge-reranker-v2-m3' (5–15 s) OK

Indizierte Dokumente
189

Chunks gesamt
3020

Mandant/Projekt-Paare
4

Erlaubte Quellpfade (ALLOWED_BASE_PATHS)
/Users/werner/Documents/reineke-watch
/Users/werner/Documents/Reineke-RAG/rag-qdrant-local/backend/tests

Zuletzt aktualisiert: 21.5.2026, 16:27:30

Admin-UI · Übersicht

Sechs grüne Status-Kacheln signalisieren, dass alle Komponenten erreichbar und betriebsbereit sind:

Kachel	Inhalt
Backend	Reineke-RAG selbst — läuft, wenn die Seite überhaupt sichtbar ist
Qdrant	Vektor-Datenbank, üblicherweise unter :6333
Ollama	Lokale LLM-Runtime, üblicherweise unter :11434
Embedding-Modell	Das in .env (oder Konfiguration) ausgewählte Embedding-Modell
Chat-Modell	Das globale Chat-Modell (per-Agent overridebar — s. Abschnitt 3)
Reranker	Cross-Encoder; lädt seine Gewichte erst beim ersten Aufruf

Darunter drei Statistik-Kacheln (indizierte Dokumente, Chunks gesamt, Mandant/Projekt-Paare) sowie die konfigurierten **erlaubten Quellpfade** (`ALLOWED_BASE_PATHS`). Pfade außerhalb dieser Liste werden von keinem UI-Schritt akzeptiert.

Die Übersicht aktualisiert sich automatisch alle 15 Sekunden, oder per Klick auf „Aktualisieren“ oben rechts.

3 · Agenten — Mandanten und Projekte

Jede sinnvolle Antwort-Kollektion besteht aus dem Paar **(Mandant, Projekt)** — intern „Agent“ genannt. Pro Agent kann eingestellt werden:

- eine **Persona** (zusätzlicher System-Prompttext — z. B. „Du beantwortest Fragen zu unseren ISMS-Richtlinien ...“),
- ein **eigenes Chat-Modell** (z. B. das große qwen2.5:32b für die Rechtsabteilung, das schnelle 14b für die FAQ),
- der **Reranker-Status** (Auto / An / Aus),
- die fertige **Pipe-Function** für OpenWebUI (mit vorausgefüllten **tenant / project**).

The screenshot shows the 'Reineke-RAG · Admin' interface. The top navigation bar includes links for 'Übersicht', 'Agenten', 'Dokumente', 'Ingest-Assistent', 'Zeitplan', 'Ingest-Verlauf', 'Logs', and 'Konfiguration'. The main heading is 'Agenten & Kollektionen'. Below this, a description states: 'Pro (Mandant, Projekt) ein Agent — vorkonfigurierte Pipe-Function und optionaler Persona-Prompt für OpenWebUI.' The interface lists four agents in a grid:

- amixon** (1 Projekt(e)): watch (61 Dok., 774 Chunks - zuletzt 2026-04-28 12:38)
- demo** (1 Projekt(e)): wiki (3 Dok., 2 Chunks - zuletzt 2026-05-20 20:37)
- reineke** (1 Projekt(e)): watch (62 Dok., 774 Chunks - zuletzt 2026-05-20 10:12)
- reineke2** (1 Projekt(e)): watch2 (63 Dok., 1470 Chunks - zuletzt 2026-05-20 19:53)

Each agent entry has buttons for 'Pipe', 'Prompt', 'Vorschau', and 'Verlauf'. An 'Aktualisieren' button is located in the top right corner of the agent list area.

Admin-UI · Agenten-Übersicht

Per Klick auf „**Prompt**“ öffnet sich der Editor für genau diesen Agenten:

Reineke-RAG · Admin Übersicht **Agenten** Dokumente Ingest-Assistent Zeitplan Ingest-Verlauf Logs Konfiguration offline · DE

Agenten & Kollektionen Aktualisieren

Pro (Mandant, Projekt) ein Agent — vorkonfigurierte Pipe-Function und optionaler Persona-Prompt für OpenWebUI.

amixon 1 Projekt(e)

watch
61 Dok., 774 Chunks · zuletzt 2026-04-28 12:38

Chat-Modell für amixon / watch — leer = globaler Fallback.
— globaler Fallback —

Reranking für amixon / watch — Auto = abhängig von Dokumentanzahl (61 Dok., Auto-Schwelle = 61 ≥ 100 → an). Aktuell: **inaktiv** (Quelle: smart-default; K = 15 aus smart-default).
Auto K (auto: 15)

Persona-Prompt für amixon / watch — wird zusätzlich zum globalen System-Prompt gesendet (max 4000 Zeichen). Leer lassen + speichern, um zu entfernen.
z. B. 'Du beantwortest Fragen zu ISMS-Richtlinien der Plasmatrete GmbH. Antworte formal und verweise auf Policy-Nummern.'

Speichern

demo 1 Projekt(e)

wiki
3 Dok., 2 Chunks · zuletzt 2026-05-20 20:37

reineke 1 Projekt(e)

watch
62 Dok., 774 Chunks · zuletzt 2026-05-20 10:12

reineke2 1 Projekt(e)

watch2
63 Dok., 1470 Chunks · zuletzt 2026-05-20 19:53

Admin-UI · Persona-Prompt bearbeiten

Die drei Formular-Blöcke arbeiten unabhängig voneinander — jeweils Wert eintippen und auf den blauen „↵“-Button klicken:

1. **Chat-Modell** — leer lassen für den globalen Fallback (aus der Konfiguration), oder ein Modell aus dem Dropdown auswählen.
2. **Reranker** — **Auto** ist der empfohlene Modus (aktiv ab 100 indizierten Dokumenten). **An** / **Aus** überschreibt die Auto-Logik dauerhaft für diesen Agenten. Das Override-K darüber legt fest, wieviele Kandidaten der Reranker zu sehen bekommt.
3. **Persona-Prompt** — bis zu 4000 Zeichen. Wird **zusätzlich** zum globalen System-Prompt geschickt, nicht statt seiner. Leeres Feld + Speichern entfernt die Persona.

Die Buttons rechts vom Agenten:

- **Pipe** — blendet eine fertig konfigurierte OpenWebUI-Pipe-Function ein (Klick auf „Kopieren“ → direkt in OpenWebUI einfügen).
- **Vorschau** — zeigt den zusammengesetzten effektiven System-Prompt (globaler Default + Persona) in einer Vorschau.
- **Verlauf** — springt zum Ingest-Verlauf gefiltert auf diesen Agenten.

Wie entsteht ein neuer Agent? Über den Ingest-Assistenten — siehe Abschnitt 5. Sobald die erste Datei dieses Paares ingestet ist, taucht der Agent automatisch hier auf.

4 · Dokumente einsehen und einzeln löschen

Die Seite **Dokumente** ist die Filter-Ansicht über alle indizierten Dateien. Standardmäßig werden gelöschte Dokumente nicht angezeigt.

Reineke-RAG · Admin
Übersicht
Agenten
Dokumente
Ingest-Assistent
Zeitplan
Ingest-Verlauf
Logs
Konfiguration
offline · DE

Dokumente

Mandant
z. B. mk-lasertechnik

Projekt
z. B. jonyx-analyse

Status
Alle (außer gelöscht)

Suche im Dateinamen
...

Suchen

Mandant	Projekt	Datei	Status	Chunks	Größe	Geändert	Fehler
reineke	watch	Plasmatreat Maßnahmenplan intern.xlsx /Users/werner/Documents/reineke-watch/Plasmatreat Maßnahmenpla...	indexed	4	81.2 KB	2024-07-08 16:33	Löschen
reineke	watch	PL.ISMS004_Richtlinie_zur_Entwicklungssicherheit.pdf /Users/werner/Documents/reineke-watch/PL.ISMS004_Richtlinie_zur...	indexed	16	869.4 KB	2025-04-25 09:41	Löschen
reineke	watch	PL.ISMS016_Richtlinie_des_Einsatzes_von_Verschlüsselun... /Users/werner/Documents/reineke-watch/PL.ISMS016_Richtlinie_des...	indexed	15	875.8 KB	2025-04-25 09:48	Löschen
reineke	watch	Plasmatreat Maßnahmenplan Schwachstellen.xlsx /Users/werner/Documents/reineke-watch/Plasmatreat Maßnahmenpla...	indexed	1	24.8 KB	2024-11-14 06:50	Löschen
reineke	watch	Security_Actions_Plasmatreat.xlsx /Users/werner/Documents/reineke-watch/Security_Actions_Plasmatre...	indexed	19	85.7 KB	2023-07-06 09:52	Löschen
reineke	watch	Security_Actions_CISO_Plasmatreat_20251231.xlsx /Users/werner/Documents/reineke-watch/Security_Actions_CISO_Pla...	indexed	6	112.1 KB	2025-12-31 13:29	Löschen
reineke	watch	PL.ISMS004_Richtlinie_zur_Entwicklungssicherheit.docx /Users/werner/Documents/reineke-watch/PL.ISMS004_Richtlinie_zur...	indexed	12	90.4 KB	2025-04-17 12:49	Löschen
reineke	watch	Plasmatreat Maßnahmenplan MB Systemhaus.xlsx /Users/werner/Documents/reineke-watch/Plasmatreat Maßnahmenpla...	indexed	17	51.9 KB	2024-06-19 06:07	Löschen
reineke	watch	PL.ISMS013_Sicherheitsverfahren_für_die_IT-Abteilung.pdf /Users/werner/Documents/reineke-watch/PL.ISMS013_Sicherheitsver...	indexed	30	982.6 KB	2025-04-25 09:46	Löschen
reineke	watch	PL.ISMS002_Datenschutzrichtlinie.docx /Users/werner/Documents/reineke-watch/PL.ISMS002_Datenschutzri...	indexed	59	160.8 KB	2025-04-25 09:39	Löschen
reineke	watch	PL.ISMS015_Richtlinie_zur_Klassifizierung_von_Information... /Users/werner/Documents/reineke-watch/PL.ISMS015_Richtlinie_zur...	indexed	22	96.9 KB	2025-04-25 09:47	Löschen
reineke	watch	Security_Actions_CISO_Plasmatreat_20250210.xlsx /Users/werner/Documents/reineke-watch/Security_Actions_CISO_Pla...	indexed	7	95.5 KB	2025-02-25 12:39	Löschen

Admin-UI · Dokumente

Die Filterleiste oben hat vier Felder:

Feld	Verhalten
Mandant / Projekt	Filter auf eines oder beide Felder gleichzeitig
Status	indexed , pending , failed , requires_ocr , deleted
Suche im Dateinamen	Substring-Suche (%foo% in SQL)

Die Tabelle zeigt pro Dokument den Status (**indexed** ist grün), die Anzahl Chunks, Dateigröße und das Datum der letzten Änderung. Falls beim Ingest ein Fehler auftrat, steht er in der Spalte „**Fehler**“ als Tooltip.

Löschen (Button rechts) markiert das Dokument in SQLite als **deleted** und löscht alle zugehörigen Vektor-Punkte aus Qdrant. Eine Wiederherstellung ist nur über einen erneuten Ingest derselben Datei möglich.

5 · Ingest-Assistent — Dokumente indexieren

Der Ingest-Assistent ist ein zweistufiger Wizard.

The screenshot shows the 'Ingest-Assistent' interface. At the top is a navigation bar with 'Reineke-RAG · Admin' and links to 'Übersicht', 'Agenten', 'Dokumente', 'Ingest-Assistent' (active), 'Zeitplan', 'Ingest-Verlauf', 'Logs', and 'Konfiguration'. The status 'offline · DE' is on the right. Below the navigation bar, the title 'Ingest-Assistent' is followed by a subtitle: 'Schritt 1: Pfad scannen → Schritt 2: Ingest starten. Pfade müssen unter einem konfigurierten **ALLOWED_BASE_PATHS**-Eintrag liegen.' The interface is divided into two main panels. The left panel, titled '1 · Pfad scannen', contains a dropdown for 'Agent (Mandant / Projekt)' with the placeholder '— Agent wählen —', a note 'Nur bestehende Agenten — neue werden über den Toggle unten angelegt.', a toggle for 'Neuen Agenten anlegen' (currently off), a text input for 'Absoluter Pfad' with the value '/mnt/rag-data/...', a checked checkbox for 'Rekursiv durchsuchen', and a blue 'Scannen' button. The right panel, titled '2 · Vorschau & Ingest', shows the message 'Noch kein Scan ausgeführt.'

Admin-UI · Ingest-Assistent

Schritt 1 (links) — Pfad scannen:

1. **Agent wählen** — entweder aus der Dropdown-Liste der bestehenden Agenten **oder** den Toggle „Neuen Agenten anlegen“ aktivieren und Mandant + Projekt eintippen.
2. **Absoluter Pfad** — muss unter einem der **ALLOWED_BASE_PATHS** liegen. Sonst lehnt das Backend ab und zeigt einen roten Hinweis.
3. **Rekursiv durchsuchen** — eingeschaltet lassen, außer der Pfad ist bewusst nur die erste Ebene.
4. Auf **Scannen** klicken.

Der Scan indexiert **nichts**, er sammelt nur, was vorhanden ist. Das Ergebnis erscheint rechts (Schritt 2):

Reineke-RAG · Admin Übersicht Agenten Dokumente **Ingest-Assistent** Zeitplan Ingest-Verlauf Logs Konfiguration offline · DE

Ingest-Assistent

Schritt 1: Pfad scannen → Schritt 2: Ingest starten. Pfade müssen unter einem konfigurierten **ALLOWED_BASE_PATHS**-Eintrag liegen.

1 · Pfad scannen

Agent (Mandant / Projekt)

amixon / watch

Nur bestehende Agenten — neue werden über den Toggle unten angelegt.

☐ Neuen Agenten anlegen

Absoluter Pfad

/Users/werner/Documents/reineke-watch

☒ Rekursiv durchsuchen

Scannen

2 · Vorschau & Ingest

Scan-Ergebnis für /Users/werner/Documents/reineke-watch

63 unterstützte Dateien 0 ignoriert .xlsx · 23 .docx · 19 .pdf · 19 .html · 2

61 bereits indexiert (werden übersprungen) 0 geändert (werden neu eingelesen) 2 neu

Heuristik basiert auf Dateigröße + Änderungsdatum. Beim eigentlichen Ingest wird zusätzlich die SHA-256-Prüfsumme verglichen.

Datei	Endung	Größe
Plasmatreat Maßnahmenplan intern 15.05.2025.xlsx	.xlsx	175.7 KB
PL.ISMS008_Richtlinie_zum_Änderungsmanagement.docx	.docx	86.9 KB
PL.ISMS016_Richtlinie_des_Einsatzes_von_Verschlüsselung.docx	.docx	91.7 KB
PL.ISMS015_Richtlinie_zur_Klassifizierung_von_Informationen.pdf	.pdf	988.2 KB
Plasmatreat Maßnahmenplan Phishing.xlsx	.xlsx	24.2 KB
PL.ISMS009_Bring_your_own_device_(BYOD)_Richtlinie.pdf	.pdf	870.1 KB
Security_Actions_CISO_Plasmatreat_20250117.xlsx	.xlsx	194.7 KB
PL.ISMS014_Richtlinie_zu_Mobilgeräten_Telearbeit_und_Arbeit_von_Zuhause_aus.docx	.docx	85.8 KB
PL.ISMS007_Kennwort_Richtlinie.docx	.docx	86.1 KB

Welche Dateitypen einlesen?

☒ .docx · 19 ☒ .html · 2 ☒ .pdf · 19 ☒ .xlsx · 23

Abgewählte Typen werden bei diesem Ingest übersprungen. Bereits indexierte Dateien dieser Typen bleiben im Bestand.

☒ Nur geänderte Dateien neu indizieren

Ingest starten

Admin-UI · Scan-Ergebnis mit Dateityp-Filter

Schritt 2 zeigt:

- eine **Übersicht der gefundenen Dateitypen** — pdf · 23 , docx · 19 , ... ,
- eine **Skip-Vorhersage** (bereits indexiert / geändert / neu) — die Heuristik nutzt Dateigröße und mtime; beim eigentlichen Ingest wird zusätzlich die SHA-256-Prüfsumme verglichen,
- eine **Stichproben-Tabelle** der ersten 200 Treffer,
- das **Dateityp-Filter-Formular** — pro gefundener Endung eine Checkbox („Welche Dateitypen einlesen?“). Abwählen ⇒ wird übersprungen.

Mit „Ingest starten“ beginnt der eigentliche Lauf. Es erscheint ein **Live-Fortschrittsbalken** mit Dateiname, vergangener Zeit, ETA, indizierten / übersprungenen / fehlgeschlagenen Zähler, plus Log-Tail am Ende. Während dieser Zeit kannst du die Seite wechseln — der Job läuft im Backend weiter; sein Verlauf bleibt im Ingest-Verlauf einsehbar.

MediaWiki-Erkennung. Liegt im Pfad ein `wiki-current.xml` plus `images/`-Ordner (und optional `LocalSettings.example.php`), schaltet der Wizard automatisch auf den Wiki-Import um — derselbe Workflow, nur mit Namespace-Auswahl statt Dateityp-Filter. Details siehe [MediaWiki-Import-Kurzanleitung](#).

6 · Zeitplan — Auto-Ingest einrichten

Quell-Verzeichnisse wachsen mit. Statt jede Nacht den Wizard zu öffnen, können Auto-Ingest-Läufe konfiguriert werden:

Admin-UI · Auto-Ingest-Zeitplan

Linke Spalte — Neuer Zeitplan:

1. **Agent wählen** (nur Agenten, die bereits Dokumente haben).
2. **Absoluter Pfad** — wie beim Ingest-Wizard.
3. **Uhrzeit (UTC, HH:MM)** — Standard 23:59 UTC, ein Lauf pro Tag.
4. **Rekursiv / Nur geänderte Dateien / Aktiv** — wie gewohnt.
5. **Zeitplan anlegen** klicken.

Rechte Spalte — Konfigurierte Zeitpläne:

Jeder Eintrag zeigt Agent, Pfad, Uhrzeit, Status (laufender Lauf, pausiert, fehlgeschlagen) und das Datum des letzten Laufs. Die kleinen Buttons pro Zeile erlauben:

- ↵, (Uhrzeit / Pfad / Optionen direkt editieren),
- **Pausieren / Aktivieren** (Toggle),
- **Jetzt ausführen** (einmal sofort, nicht zum nächsten Trigger warten),
- **Löschen**.

Der Scheduler lebt im FastAPI-Process. Beim Backend-Neustart wird er automatisch aus der DB-Tabelle `ingest_schedules` wiederbelebt — keine separate Service-Datei nötig.

7 · Ingest-Verlauf — was lief wann?

Die Seite **Ingest-Verlauf** zeigt alle bisherigen Läufe — manuell, geplant, MediaWiki, alles in einer Tabelle:

Reineke-RAG · Admin
Übersicht
Agenten
Dokumente
Ingest-Assistent
Zeitplan
Ingest-Verlauf
Logs
Konfiguration
offline · DE

Ingest-Verlauf

Aktualisieren

Mandant

Projekt

Gestartet	Mandant	Projekt	Pfad	Status	Gefunden	Indiziert	Unverändert	Fehler	Chunks	Beendet
2026-05-20 19:51:35	reineke2	watch2	/Users/werner/Documents/reineke-watch	completed	63	63	0	0	1470	2026-05-20 19:53:36
2026-05-20 10:10:34	reineke	watch	/Users/werner/Documents/reineke-watch	completed	61	61	0	0	774	2026-05-20 10:12:00
2026-04-28 12:37:42	amixon	watch	/Users/werner/Documents/reineke-watch	completed	61	61	0	0	774	2026-04-28 12:38:46
2026-04-28 12:37:28	reineke	watch	/Users/werner/Documents/reineke-watch	completed	61	0	61	0	0	2026-04-28 12:37:28
2026-04-28 12:36:59	reineke	watch	/Users/werner/Documents/reineke-watch	completed	61	0	61	0	0	2026-04-28 12:36:59
2026-04-28 12:36:09	reineke	watch	/Users/werner/Documents/reineke-watch	completed_with_errors	62	0	61	1	0	2026-04-28 12:36:09
2026-04-28 08:36:42	reineke	watch	/Users/werner/Documents/reineke-watch	completed	61	61	0	0	767	2026-04-28 08:37:46

Zeige bis zu 200 letzte Läufe.

Admin-UI · Ingest-Verlauf

Spalten:

Spalte	Bedeutung
Gestartet / Beendet	Zeitstempel (lokale Zeitzone)
Mandant / Projekt	Agent des Laufs
Pfad	Quell-Pfad
Status	completed, completed_with_errors, running, failed
Gefunden	Dateien im Scan
Indiziert / Unverändert	Neu/aktualisiert oder übersprungen
Fehler	Anzahl Dateifehler (completed_with_errors lohnt einen Blick)
Chunks	Insgesamt erzeugte Vektor-Chunks

Klick auf eine Zeile öffnet den **detaillierten Log** des Laufs (vollständig oder als Download). So lässt sich auch im Nachhinein nachvollziehen, warum z. B. drei PDFs als **failed** markiert wurden („LibreOffice fehlt“, „Embedding context length exceeded“, ...).

Filter oben rechts (Mandant, Projekt) blenden gezielt einen Agenten ein.

8 · Logs — API-Audit und Anwendungs-Log live

Die Seite **Logs** hat zwei Tabs:

Reineke-RAG · Admin
Übersicht
Agenten
Dokumente
Ingest-Assistent
Zeitplan
Ingest-Verlauf
Logs
Konfiguration
offline · DE

Logs

API-Aufrufe
Anwendungslog

Status

Methode

Mandant

Alle

Alle

Filtern

Live-Tail starten

Zeitstempel	Methode	Pfad	Status	Dauer	Mandant	Projekt	IP	Fehler
2026-05-21 14:27:46	GET	/admin/logs	200	0 ms			127.0.0.1	
2026-05-21 14:27:44	GET	/admin/api/jobs	200	1 ms			127.0.0.1	
2026-05-21 14:27:44	GET	/admin/jobs	200	0 ms			127.0.0.1	
2026-05-21 14:27:42	GET	/admin/api/schedules	200	1 ms			127.0.0.1	
2026-05-21 14:27:42	GET	/admin/api/tenants.json	200	0 ms			127.0.0.1	
2026-05-21 14:27:42	GET	/admin/zeitplan	200	0 ms			127.0.0.1	
2026-05-21 14:27:40	GET	/admin/api/tenants.json	200	0 ms			127.0.0.1	
2026-05-21 14:27:40	GET	/admin/ingest	200	0 ms			127.0.0.1	
2026-05-21 14:27:38	GET	/admin/api/documents?tenant=reineke&project=watch	200	2 ms	reineke	watch	127.0.0.1	
2026-05-21 14:27:38	GET	/admin/dokumente?tenant=reineke&project=watch	200	0 ms	reineke	watch	127.0.0.1	
2026-05-21 14:27:35	GET	/admin/api/ollama/models?role=chat	200	9 ms			127.0.0.1	
2026-05-21 14:27:35	GET	/admin/api/ollama/models?role=chat	200	7 ms			127.0.0.1	
2026-05-21 14:27:35	GET	/admin/api/ollama/models?role=chat	200	9 ms			127.0.0.1	
2026-05-21 14:27:35	GET	/admin/api/ollama/models?role=chat	200	8 ms			127.0.0.1	
2026-05-21 14:27:35	GET	/admin/api/tenants	200	2 ms			127.0.0.1	
2026-05-21 14:27:35	GET	/admin/agenten	200	0 ms			127.0.0.1	
2026-05-21 14:27:33	GET	/admin/api/ollama/models?role=chat	200	9 ms			127.0.0.1	
2026-05-21 14:27:33	GET	/admin/api/ollama/models?role=chat	200	11 ms			127.0.0.1	
2026-05-21 14:27:33	GET	/admin/api/ollama/models?role=chat	200	8 ms			127.0.0.1	

Zeige bis zu 300 letzte Einträge.

Admin-UI · API-Audit-Log

8.1 Tab „API-Aufrufe“

Jede HTTP-Anfrage an das Backend (außer den SSE-Streams selbst) wird in der Tabelle `request_logs` festgehalten. Die Filter oben:

- **Status** — Alle / Nur Fehler (≥ 400) / 200 / 400 / 404 / 500,
- **Methode** — GET / POST / DELETE,
- **Mandant** — frei eintippbar.

Die Liste ist Newest-First, paginiert auf 300 Einträge. „**Live-Tail starten**“ öffnet eine SSE-Verbindung — neue Anfragen erscheinen oben, das Frontend rendert sie sofort.

8.2 Tab „Anwendungslog“

Tails die rotierende Logdatei `storage/logs/app.log` (5 × 5 MB). Pro Backend-Aufruf, Embedding, Chat-Antwort sowie für jeden Scheduler-Job landet hier eine Logzeile mit Ebene (INFO, WARNING, ...). Praktisch, um während eines laufenden Ingests zu sehen, woran das Backend gerade arbeitet.

9 · Konfiguration — Werte zur Laufzeit ändern

Die Seite **Konfiguration** überlagert ausgewählte `.env`-Werte mit Datenbank-Overrides — Änderungen wirken sofort, ohne Backend-Neustart. Werte, die Reboot-relevant sind (Hosts, Pfade, API-Keys), werden separat darunter „read-only“ angezeigt.

Reineke-RAG · Admin
Übersicht
Agenten
Dokumente
Ingest-Assistent
Zeitplan
Ingest-Verlauf
Logs
Konfiguration
offline · DE

Konfiguration

Aktualisieren

Editierbare Werte werden zur Laufzeit angewendet und persistiert. Infrastruktur- und Sicherheitsfelder (Hosts, Pfade, API-Keys) sind nur über `.env` änderbar und erfordern einen Neustart.

Schlüssel	Wert	Aktion
EMBEDDING_MODEL Embedding-Modell Wähle eines der in Ollama installierten Embedding-Modelle. ▲ Modellwechsel erzeugt Vektoren anderer Dimension – bestehende Qdrant-Collection muss neu angelegt und alle Dokumente neu ingestet werden.	bge-m3 (nicht installiert) 	env
CHAT_MODEL Chat-Modell · globaler Fallback Wird verwendet, wenn ein Agent kein eigenes Modell gesetzt hat. Per-Agent-Override findest du auf der Agenten-Seite.	qwen2.5:32b-instruct-q4_K_M 	env
OLLAMA_KEEP_ALIVE Ollama Keep-Alive Wie lange Ollama Modelle nach dem letzten Request im VRAM hält. Format: '5m', '1h', '24h', '-1' (für immer), '0' (sofort entladen).	1h 	env
CHUNK_SIZE Chunk-Größe (Zeichen) Maximale Zeichenzahl pro Chunk für PDF/DOCX/DOC.	1000 	env
CHUNK_OVERLAP Chunk-Overlap (Zeichen) Überlappung zwischen aufeinanderfolgenden Chunks.	150 	env
XLSX_ROWS_PER_CHUNK XLSX-Zeilen pro Chunk Wieviele Tabellenzeilen kommen in einen Chunk.	40 	env
XLSX_MAX_CHARS_PER_CHUNK XLSX max. Zeichen pro Chunk Hard-Cap, schützt das Embedding-Kontextfenster.	6000 	env
RETRIEVAL_TOP_K Retrieval Top-K Wieviele Chunks werden pro Frage aus Qdrant geholt.	12 	env
MIN_RETRIEVAL_SCORE Min. Score-Schwelle Treffer unterhalb dieses Cosine-Scores werden verworfen.	0.25 	env
CHAT_TEMPERATURE Chat-Temperatur 0 = deterministisch / extrahierend, höher = kreativer.	0.1 	env

Admin-UI · Konfiguration

Pro Zeile: Schlüssel + Beschreibung links, aktueller Wert mittig (als Eingabefeld bzw. Dropdown), Aktionspalte rechts. Auf „“ klicken speichert. Ist ein Override gesetzt, erscheint rechts ein „override“-Badge — mit dem Reset-Button daneben kehrt der Wert zurück auf das, was in `.env` (bzw. Default) steht.

Übliche Anwendungsfälle:

Was ich ändern will	Schlüssel
Anderes globales Embedding-Modell	<code>EMBEDDING_MODEL</code>
Anderes globales Chat-Modell	<code>CHAT_MODEL</code> (pro Agent: Agenten-Seite)
Chat „kreativer“ stellen	<code>CHAT_TEMPERATURE</code> (z. B. 0.3)
Längere Antworten zulassen	<code>CHAT_MAX_TOKENS</code>
Mehr Treffer zurück	<code>RETRIEVAL_TOP_K</code>
Niedrigere Score-Schwelle	<code>MIN_RETRIEVAL_SCORE</code>
Mehr Konversationsgedächtnis	<code>CHAT_HISTORY_TURNS</code>
Log-Level	<code>LOG_LEVEL</code>

Unter der Konfigurationstabelle findet sich:

- **Globaler System-Prompt** — Override für den Standard-Anti-Halluzinations-Prompt. Persona-Prompts ergänzen, ersetzen ihn jedoch nicht.
- **OpenWebUI · Pipe-Function** — der nicht agentenspezifische Quelltext der Pipe (auf der Agenten-Seite gibt es pro Agent eine vorbefüllte Variante).

Modellwechsel auf eine andere Vektor-Dimension (z. B. von `bge-m3` 1024-dim auf `nomic-embed-text` 768-dim) zwingt zu einem Re-Index. Das gelbe Warnsymbol an der Zeile macht darauf aufmerksam.

10 · Ein typischer Tagesablauf

Drei Mini-Use-Cases als Quick-Reference:

10.1 Neuen Dokumenten-Ordner einbinden

1. `ALLOWED_BASE_PATHS` in `.env` (oder im Compose-Setup) um das neue Verzeichnis erweitern · Backend neu starten.
2. Im Ingest-Assistenten „**Neuen Agenten anlegen**“ ⇒ Mandant + Projekt eintippen ⇒ Pfad eingeben ⇒ **Scannen** ⇒ **Ingest starten**.
3. Optional: auf der Agenten-Seite einen Persona-Prompt setzen (z. B. „Du beantwortest Fragen zu Vertriebshandbüchern; antworte knapp und nenne immer den Quell-Abschnitt.“).
4. Im Zeitplan einen täglichen Auto-Ingest auf demselben Pfad anlegen.

10.2 Eine Datei wurde verschoben oder gelöscht

- **Datei verschoben:** Pfad scannen (alter Pfad) ⇒ „Mit löschen“ zustimmen oder per API `POST / documents/reindex-changed?mark_missing_as_deleted=true`. Anschließend neuen Pfad scannen + ingesten.
- **Einzelne Datei löschen:** Auf der Dokumente-Seite filtern, **Löschen** klicken. Der Vektorbestand wird sofort entfernt.

10.3 Eine Antwort sieht falsch aus

1. **Logs** → **API-Aufrufe** → letzte `/chat` -Anfrage suchen, Status prüfen.
 2. **Konfiguration** → `MIN_RETRIEVAL_SCORE` testweise von 0.35 auf 0.20 senken; erneut fragen. Falls jetzt sinnvolle Quellen kommen, war die Schwelle zu strikt.
 3. **Konfiguration** → `RETRIEVAL_TOP_K` von 6 auf 8 erhöhen.
 4. **Agenten** → Reranker auf „An“ zwingen, falls noch nicht aktiv.
 5. **Agenten** → Persona schärfen („Antworten ausschließlich auf Basis der Tabellen in den Dokumenten ...“).
-

11 · Standard-Antwortmuster

Reineke-RAG ist auf **Treue zum Quellmaterial** trainiert. Wenn das System keine ausreichend relevante Quelle findet, antwortet es mit dem Fallback-Text — und ruft das LLM gar nicht erst auf:

„Das steht nicht eindeutig in den bereitgestellten Dokumenten.“

Das ist **keine Fehlfunktion**, sondern Absicht: Lieber ehrlich „weiß ich nicht“ als eine erfundene Antwort. Die übliche Reaktion auf dieses Verhalten ist eine der oben genannten Stellschrauben (Score-Schwelle, Top-K, Reranker, Persona).

Echte Antworten enden mit einem **Quellenblock** — eine Liste der verwendeten Dateifragmente mit Seite, Sheet/Zeilen und Chunk-Index. Bei MediaWiki-Quellen ist die Wiki-URL klickbar.

12 · Wo finde ich was?

Frage	Ort im UI
Läuft Reineke-RAG?	Übersicht (Health-Kacheln)
Wie viele Dokumente sind drin?	Übersicht (Statistik-Kacheln)
Welche Agenten gibt es?	Agenten
Welche Dateien gehören zu einem Agenten?	Dokumente (mit Mandant/Projekt-Filter)
Eine Datei wegnehmen?	Dokumente → Löschen
Neuen Ordner indexieren?	Ingest-Assistent
Wiki indexieren?	Ingest-Assistent (Pfad mit <code>wiki-current.xml</code>)
Tägliche Auto-Aktualisierung?	Zeitplan
Hat der letzte Ingest funktioniert?	Ingest-Verlauf
Warum hat das LLM langsam geantwortet?	Logs → Anwendungslog
Wer hat heute Mittag was abgefragt?	Logs → API-Aufrufe
Antworten kreativer machen?	Konfiguration → <code>CHAT_TEMPERATURE</code>
OpenWebUI anbinden?	Konfiguration → Pipe-Function bzw. Agenten → Pipe
Globalen Antwort-Stil anpassen?	Konfiguration → Globaler System-Prompt

Bei Fragen oder Fehlern: Reineke-Technik · support@reineke-technik.de. Vor dem Support-Kontakt bitte einen Tail des Anwendungs-Logs sowie eine relevante Zeile aus den API-Aufrufen mitschicken.